# ZHOU_Mengzhe.qmd

## Introduction à la classification non-supervisée - Application à l'élection présidentielle 2017

```
library(tidyverse)
```

```
Warning: package 'tidyverse' was built under R version 4.4.3
```

```
Warning: package 'ggplot2' was built under R version 4.4.3
```

```
Warning: package 'tibble' was built under R version 4.4.3
```

```
Warning: package 'tidyr' was built under R version 4.4.3
```

```
Warning: package 'readr' was built under R version 4.4.3
```

```
Warning: package 'purrr' was built under R version 4.4.3
```

```
Warning: package 'dplyr' was built under R version 4.4.3
```

```
Warning: package 'stringr' was built under R version 4.4.3
```

```
Warning: package 'forcats' was built under R version 4.4.3
```

```
Warning: package 'lubridate' was built under R version 4.4.3
```

```
-- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0 --
v dplyr     1.2.1     v readr     2.2.0
v forcats   1.0.1     v stringr   1.6.0
v ggplot2   4.0.3     v tibble    3.3.1
v lubridate 1.9.5     v tidyr     1.3.2
v purrr     1.2.2
-- Conflicts ------------------------------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to becor
```

```r
library(ggplot2)
library(dplyr)
library(fossil)
```

```
Warning: package 'fossil' was built under R version 4.4.3

Loading required package: sp
Loading required package: maps

Warning: package 'maps' was built under R version 4.4.3


Attaching package: 'maps'

The following object is masked from 'package:purrr':

    map

Loading required package: shapefiles

Warning: package 'shapefiles' was built under R version 4.4.3

Loading required package: foreign

Attaching package: 'shapefiles'

The following objects are masked from 'package:foreign':

    read.dbf, write.dbf
```

## Clustering Ascendant Hiérarchique (CAH)

### Classification des départements

1.

```
data <- read.csv("Presidentielle2017_par_departement.csv")
voting_col <- c("Abstentions", "Blancs","Arthaud", "Asselineau",
                "Cheminade", "DupontAignan", "Fillon", "Hamon",
                "Lasalle", "LePen", "Macron", "Melenchon", "Poutou")

voting_data <- data[,voting_col]

rownames(voting_data) <- data$Dpt


# Calculer disdance de Matrice(avec euclidienne)
dist_matrice <- dist(voting_data, method = "euclidean")

# CAH Ward
hclust_res <- hclust(dist_matrice, method = "ward.D2")

# arbre
plot(hclust_res , cex = 0.6, main = "CAH des départements français")
```

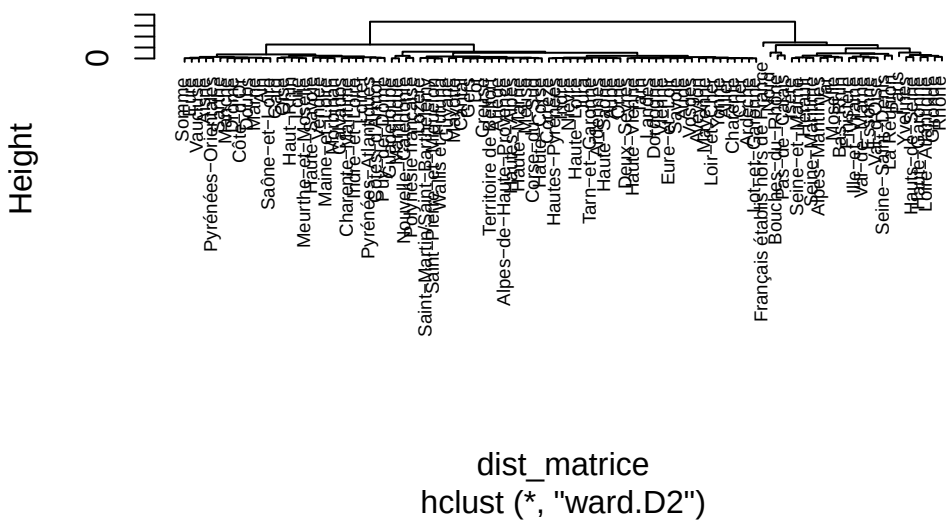

```r
cluster <- cutree (hclust_res , k = 3)

cluster
```

```
                  Ain                 Aisne
                    1                     1
               Allier Alpes-de-Haute-Provence
                    1                     1
         Hautes-Alpes       Alpes-Maritimes
                    1                     2
              Ardèche              Ardennes
                    1                     1
              Ariège                 Aube
                    1                     1
                Aude               Aveyron
                    1                     1
  Bouches-du-Rhône              Calvados
                    2                     1
              Cantal             Charente
                    1                     1
  Charente-Maritime                Cher
                    1                     1
            Corrèze          Corse-du-Sud
                    1                     1
        Haute-Corse             Côte-d'Or
                    1                     1
    Côtes-d'Armor                Creuse
                    1                     1
         Dordogne                Doubs
                    1                     1
             Drôme                Eure
                    1                     1
       Eure-et-Loir            Finistère
                    1                     2
             Gard           Haute-Garonne
                    1                     2
             Gers                Gironde
                    1                     2
          Hérault       Ille-et-Vilaine
                    2                     2
            Indre          Indre-et-Loire
                    1                     1
```

| | |
|---|---|
| Isère | Jura |
| 2 | 1 |
| Landes | Loir-et-Cher |
| 1 | 1 |
| Loire | Haute-Loire |
| 1 | 1 |
| Loire-Atlantique | Loiret |
| 2 | 1 |
| Lot | Lot-et-Garonne |
| 1 | 1 |
| Lozère | Maine-et-Loire |
| 1 | 1 |
| Manche | Marne |
| 1 | 1 |
| Haute-Marne | Mayenne |
| 1 | 1 |
| Meurthe-et-Moselle | Meuse |
| 1 | 1 |
| Morbihan | Moselle |
| 1 | 2 |
| Nièvre | Nord |
| 1 | 2 |
| Oise | Orne |
| 1 | 1 |
| Pas-de-Calais | Puy-de-Dôme |
| 2 | 1 |
| Pyrénées-Atlantiques | Hautes-Pyrénées |
| 1 | 1 |
| Pyrénées-Orientales | Bas-Rhin |
| 1 | 2 |
| Haut-Rhin | Rhône |
| 1 | 2 |
| Haute-Saône | Saône-et-Loire |
| 1 | 1 |
| Sarthe | Savoie |
| 1 | 1 |
| Haute-Savoie | Paris |
| 1 | 2 |
| Seine-Maritime | Seine-et-Marne |
| 2 | 2 |
| Yvelines | Deux-Sèvres |
| 2 | 1 |
| Somme | Tarn |

```
                         1                                  1
               Tarn-et-Garonne                            Var
                         1                                  2
                     Vaucluse                          Vendée
                         1                                  1
                       Vienne                    Haute-Vienne
                         1                                  1
                       Vosges                          Yonne
                         1                                  1
        Territoire de Belfort                         Essonne
                         1                                  2
              Hauts-de-Seine                Seine-Saint-Denis
                         2                                  2
                Val-de-Marne                       Val-d'Oise
                         2                                  2
                  Guadeloupe                       Martinique
                         1                                  1
                      Guyane                        La Réunion
                         1                                  2
                     Mayotte                Nouvelle-Calédonie
                         1                                  1
          Polynésie française           Saint-Pierre-et-Miquelon
                         1                                  1
             Wallis et Futuna     Saint-Martin/Saint-Barthélemy
                         1                                  1
Français établis hors de France
                         3
```

Repondre:

- Pour calculer la distance, utilisez la distance euclidienne.
- Pour la réalisation d'un clustering hiérarchique, utilisez Word
- En utilisant cutree(), vous pouvez voir la catégorie à laquelle appartient chaque province. J'ai divisé en 3 catégories.

2.

Repondre

- Le dendrogramme a déjà été tracé dans 1.

- La signification des valeurs sur l'axe vertical du dendrogramme : elles représentent la distance lors de la fusion de deux provinces. Plus la hauteur est faible, plus elles sont fusionnées tôt, donc plus elles sont similaires.
- "Français établis hors de France" a été fusionné avec les autres provinces en dernier, ce qui indique qu'il présente des différences très importantes par rapport aux autres catégories.

3.

```
# Identifier les valeurs aberrantes
cluster_5 <- cutree(hclust_res, k = 5)
table(cluster_5)
```

```
cluster_5
 1  2  3  4  5
29 52 22  3  1
```

```
# trouver les valeurs aberrantes
outlier_group <- which.min(table(cluster_5))
outlier_departments <- names(cluster_5[cluster_5 == outlier_group])

# eliminer les valeurs aberrantes
clean_data <- voting_data[cluster_5 != outlier_group,]

# reclassifier
dist_matrice_clean <- dist(clean_data, method = "euclidean")
hclust_clean <- hclust(dist_matrice_clean, method = "ward.D2")
cluster_clean <- cutree(hclust_clean, k = 2)

table(cluster_clean)
```

```
cluster_clean
 1  2
81 25
```

```
# plus petit group:
small_group <- which.min(table(cluster_clean))
small_group_department <- names(cluster_clean[cluster_clean == small_group])

print(small_group_department)
```

```
 [1] "Alpes-Maritimes"   "Bouches-du-Rhône"  "Finistère"
 [4] "Haute-Garonne"     "Gironde"           "Hérault"
 [7] "Ille-et-Vilaine"   "Isère"             "Loire-Atlantique"
[10] "Moselle"           "Nord"              "Pas-de-Calais"
[13] "Bas-Rhin"          "Rhône"             "Paris"
[16] "Seine-Maritime"    "Seine-et-Marne"    "Yvelines"
[19] "Var"               "Essonne"           "Hauts-de-Seine"
[22] "Seine-Saint-Denis" "Val-de-Marne"      "Val-d'Oise"
[25] "La Réunion"
```

Hypothèse : probablement lié à la population des départements.

```r
# Varifier:
group_profiles <- aggregate(clean_data,
                            by = list(Cluster = cluster_clean),
                            FUN = mean)

clean_data_with_cluster <- cbind(clean_data, Cluster = cluster_clean)
group_analysis <- clean_data_with_cluster %>%
  group_by(Cluster) %>%
  summarise(across(everything(), mean))

print(group_analysis)
```

```
# A tibble: 2 x 14
  Cluster Abstentions Blancs Arthaud Asselineau Cheminade DupontAignan  Fillon
    <int>       <dbl>  <dbl>   <dbl>      <dbl>     <dbl>        <dbl>   <dbl>
1       1      61693.  4354.   1597.       1874      410.       11095.  42937.
2       2     195079. 12166.   4068.       7007     1253.       31499. 143570.
# i 6 more variables: Hamon <dbl>, Lasalle <dbl>, LePen <dbl>, Macron <dbl>,
#   Melenchon <dbl>, Poutou <dbl>
```

Ne correspond pas au problème de distribution basé sur les votes par département.

Le plus petit groupe contient 25 départements, correspondant principalement

aux grandes villes et aux zones densément peuplées.

Les résultats de validation montrent que tous les indicateurs de vote du deuxième groupe sont plus élevés que ceux du premier groupe,

Cela ne correspond donc pas à l'objectif initial de classification par département.

La raison pourrait être l'utilisation du nombre de votes bruts plutôt que des pourcentages pour calculer les distances.

4.

```r
# Méthode améliorée : utiliser les données en pourcentage
percentage_data <- voting_data
total_votes <- rowSums(percentage_data)
percentage_data <- percentage_data / total_votes * 100
rownames(percentage_data) <- data$Dpt

# 2. départements de France métropolitaine
metropolitan_codes <- c(1:95, "2A", "2B")
metro_indices <- which(data$CodeDpt %in% metropolitan_codes)
metro_data <- percentage_data[metro_indices, ]

# 3. Refaire le clustering
dist_metro <- dist(metro_data, method = "euclidean")
hclust_metro <- hclust(dist_metro, method = "ward.D2")
plot(hclust_metro, cex = 0.7, main = "Classification avec données en pourcentage")
```

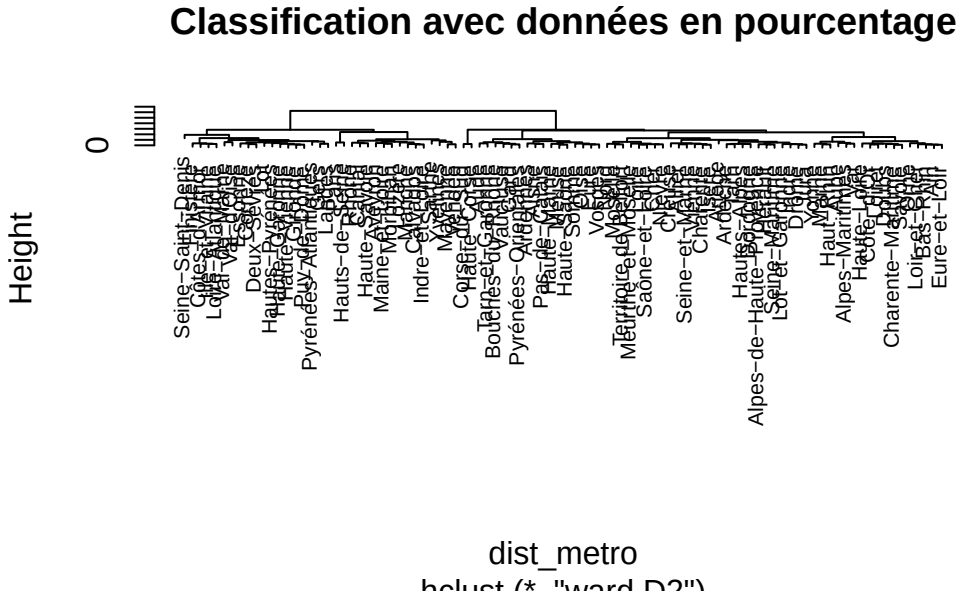


```r
clusters_metro <- cutree(hclust_metro, k = 4)
table(clusters_metro)
```

```
clusters_metro
 1  2  3  4
59 16 19  2
```

```r
metro_with_cluster <- cbind(metro_data, Cluster = clusters_metro)
group_analysis <- metro_with_cluster %>%
  group_by(Cluster) %>%
  summarise(across(everything(), mean))

print(group_analysis)
```

```
# A tibble: 4 x 14
  Cluster Abstentions Blancs Arthaud Asselineau Cheminade DupontAignan Fillon
    <int>       <dbl>  <dbl>   <dbl>      <dbl>     <dbl>         <dbl>  <dbl>
1       1        20.5   1.49   0.560      0.705     0.147          4.15   14.8
2       2        18.1   1.48   0.516      0.639     0.146          3.76   19.5
3       3        19.1   1.47   0.488      0.692     0.141          3.53   13.8
4       4        32.1   1.23   0.213      0.418     0.109          1.93   17.0
# i 6 more variables: Hamon <dbl>, Lasalle <dbl>, LePen <dbl>, Macron <dbl>,
#   Melenchon <dbl>, Poutou <dbl>
```

En utilisant les données en pourcentage, on peut éliminer l'influence de la taille de la population.

À ce moment, les valeurs aberrantes ne sont plus définies par la taille démographique.

5.

```r
# Ward
hclust_ward <- hclust(dist_metro, method = "ward.D2")
clusters_ward <- cutree(hclust_ward, k = 4)

# Single
hclust_single <- hclust(dist_metro, method = "single")
clusters_single <- cutree(hclust_single, k = 4)

# Complete
hclust_complete <- hclust(dist_metro, method = "complete")
clusters_complete <- cutree(hclust_complete, k = 4)


table(clusters_ward)
```

```
clusters_ward
 1  2  3  4
59 16 19  2
```